

Jev, Vibe Check 🎧

Decision Offloading

판정을 분리하면,
에이전트는 무엇을 얻을까?




Jev

by TypeSafe AI



GEODE

Self-evolve agent harness



판정 위임의 설계와 검증


판정을 위임하면 에이전트는 무엇을 얻을까 · 한국어 13:29, 영어 13:32

01	질문과 시스템 Jev 공개 표면 · 연구 질문 · GEODE와 판정 교체	0:13
02	구현과 파일럿 개발 스캐폴드 · 파일럿 관측 · 공개 표면과 연구 근거	1:25
03	설계와 방법 비교와 완료 기준 · 자료와 생성 규칙 · 절차와 트랙 · 정책 동결과 분석 · 지표 읽기 가이드	3:34
04	작업별 품질 완료 판정 · Choice · Joint 판정 · Noul · 의도와 대상 · 후보 선택 · Score · 외부 궤적 판정 · 외부 후보 선택	7:01
05	시간과 비용 본 실험 · verifier 지연 · 호출과 회계 범위	8:13
06	신호와 정책 반복 일관성 · 오류 구분과 보정 · 동결한 조건부 위임	8:32
07	실제 실행 반복 실행 · 결함 주입 · 수리와 전달	9:17
08	적용과 재현 운영 조건 · 공개 기록 · 독자의 검토 경로 · 원문과 제작 근거	12:24
09	결론 관측과 적용 판단	13:15

판정 위임의 설계와 검증

판정을 위임하면 에이전트는 무엇을 얻을까 · 한국어 13:29, 영어 13:32

01	질문과 시스템 Jev 공개 표면 · 연구 질문 · GEODE와 판정 교체	0:13
02	구현과 파일럿 개발 스캐폴드 · 파일럿 관측 · 공개 표면과 연구 근거	1:25
03	설계와 방법 비교와 완료 기준 · 자료와 생성 규칙 · 절차와 트랙 · 정책 동결과 분석 · 지표 읽기 가이드	3:34
04	작업별 품질 완료 판정 · Choice · Joint 판정 · Noul · 의도와 대상 · 후보 선택 · Score · 외부 궤적 판정 · 외부 후보 선택	7:01
05	시간과 비용 본 실험 · verifier 지연 · 호출과 회계 범위	8:13
06	신호와 정책 반복 일관성 · 오류 구분과 보정 · 동결한 조건부 위임	8:32
07	실제 실행 반복 실행 · 결함 주입 · 수리와 전달	9:17
08	적용과 재현 운영 조건 · 공개 기록 · 독자의 검토 경로 · 원문과 제작 근거	12:24
09	결론 관측과 적용 판단	13:15



SOUNDTRACK

Nemzzz

LOCKED IN · 드릴 · 136–151 BPM

01	GASS feat. Travis Scott ■□□□ ■□□□ ■□■□ ■□■□	140 BPM 0:00–1:54
02	KILLIN EM ■□■□ ■□■□ ■□■□ ■□■□	144 BPM 1:54–3:47
03	TODAY □□□□ □□■□ □□□□ ■□□□	142 BPM 3:47–5:50
04	TOKYO DRIFT ■□■□ □□■□ □□■□ ■□□□	136 BPM 5:50–7:38
05	PRINCE OF THE SCENE ■□□□ ■□□□ ■□□□ □□□□	149 BPM 7:38–9:34
06	4AM ■□□□ ■□□□ ■□□□ ■□□□	151 BPM 9:34–12:10

첫 순환 시간 · 실측 808 큐와 페이지별 읽기 시간
6곡 뒤 GASS부터 반복

판단을 코드로 연결하는 세 가지 프리미티브



Jev · 코드가 읽는 판단과 확률

상태·질문에 대한 타입별 응답과 확률. 후속 동작은 호출 코드의 책임.

질문 타입

- Choice · 선택지 분류

형식이 정해진 답

choice + probabilities
confidence

- Noul · 예 / 아니요

p

$P(\text{yes}) \in [0, 1]$

- Score · 서열 기준 평가

Σ

$\text{score} = \Sigma i \times P(i)$

legend · probabilities · confidence

label: P(·)

...

코드의 다음 동작



다음 분기 선택



조건 검사



기준별 후보 정렬

공개된 호출 계약과 미확인 내부 구조

명세로 확인한 호출 경계

POST /v1/systemone

model	호출할 모델
state	요청 · 후보 · 도구 관측
questions	질문 이름 · 문장 · 응답 타입

반환되는 값

질문별 타입에 맞는 답과 확률
독립 질문은 한 state로 묶어 호출
앞선 답에 의존하는 질문은 다음 호출로 분리

호출 코드의 뭉: 수용 기준 · 다음 행동 · retry / repair budget

이번 연구의 검증 대상은 반환된 판단과 GEODE의 후속 동작. Jev 내부 구조의 재현은 아님.

이 명세만으로 알 수 없는 것

공급사 설명
New architecture · parallel sampler
RLCD
출시 글·개발자 설명, 공개 구현 검증과는 별도

검토한 공개 자료에서 확인 못함
Backbone · attention mask · loss · weights

특정 LLM에서 인코더 혹은 디코더를 가져왔을
가능성은 미확인. API 형식만으로 구조를 추론 불가.

빠른 판단은 언제 맡길 수 있는가

최종 native 근거 · 편집 해석

실행 원본 보존 · 교정 분석은 별도 표기

판단 종류와 완료 계약에 따른 위임 범위

고정 의도 분류

같은 intent와 target을 정확히 고르는가?
패널의 항목 정확도와 실제 과제 완료율의 구분

Noul joint · 후보 선택

두 조건과 후보 순위에서도 품질을 유지하는가?
Primitive별로 고정된 비교 단위

확률 · 조건부 위임


불확실한 판단을 더 강한 verifier로 넘길 수 있는가?
정책 동결 후 패널 평가와 실제 실행을 분리

검증 대상: 같은 입력의 품질 · 오류를 구별하는 신호 · 최종 산출물 반환

누가 만들고, 무엇을 검증할까?

사람의 질문에서 검증 가능한 결과까지

제작 호스트 ≠ 비교 대상 모델



GEODE의 실행 지도, 라운드와 완료 검증의 경계

요청 · 세션 · 실행 범위 · 남은 예산
입력 준비 후, 한 physical turn 안에서 라운드 반복




GEODE의 실행 지도, 라운드와 완료 검증의 경계



Jev가 들어갈 자리, 판단과 실행의 분리

메인 실행 루프는 그대로
현재 core의 Jev 경로는 명시적 선택 시에만



Choice · 완료 판정

입력	원 요청 · 완료 후보 · 보존된 관측
GEODE 변환	passed · should_retry · feedback
소비	finalizer · 전달 / 수정 / 보류

실행 권한·수정 예산은 GEODE 소유

Choice · 관측 근거 분류

입력	관측 + 유계 인지 상태
변경	코드가 정한 다음 확인사항을 subgoals에 추가
소비	다음 Reflection · 상태 기록

hypotheses·confidence 생성이나 root 프롬프트 주입이 아님

도구 완료 기록 후 Reflection

평가 전용 · opt-in

Choice 의도·대상 분류

analyze_request가 root 문맥으로 반환 · 행동 실행이나 승인 아님

Jev가 들어갈 자리, 판단과 실행의 분리

메인 실행 루프는 그대로
현재 core의 Jev 경로는 명시적 선택 시에만



설계 당시 비교 · main 구현 경로와 구분


Score	동결된 같은 4개 후보의 선택 품질 현재 candidate_sampling의 선택기는 LLM
Noul	모순 관측과 필수 근거 누락을 따로 판정 두 조건의 joint 판정과 이후 복구를 함께 측정
Cascade	불확실한 Jev 판정만 Astra 검토로 판정 경계·호출 비용·거짓 수락을 함께 비교

전역 LLM 유지 · 지정한 판단 지점만 교체

평가 전용 · opt-in	Choice 의도·대상 분류 analyze_request가 root 문맥으로 반환 · 행동 실행이나 승인 아님
----------------	--

하나의 계약, 두 호스트의 작업 문맥

HOST · 시스템 지침 / 도구 / 권한·샌드박스



AGENTS.md, 필요한 지침을 찾아가는 지도

공통 계약에서 필요한 근거까지

AGENTS.md

범위 · 소유권 · 완료 조건 · 검증 책임
Codex 직접 읽기 · CLAUDE.md → @AGENTS.md

- docs/workflow.md → 작업별 owner
요청을 코드·문서의 실제 담당 경로에 연결
- .agents/skills/ → SKILL.md
.claude/skills/는 같은 파일을 가리키는 별칭
- 필요한 references/ → 코드·호출부·테스트
선택한 스킬은 전체를 읽고, 근거로 내려가기

이번 작업에서 선택한 경로

설계·측정

geode-eval · stanford-test-time-compute
05 사전등록 + 06 신뢰도 렌즈 → 동결·admission

구현·통합

geode-workflow · geode-gitflow
역할별 작업 계약 → 패치 → 담당자 검증·통합

영상·검수


technical-deck-report · viz-frame-audit
DESIGN.md + fluent-korean → KO/EN 렌더·검수

위임 계약 역할·입력·수정 범위·완료 조건 → spawn → 패치·findings 반환

수정 이터레이션 담당자 재현·검사 → 결함 반환 → 수정·재검사

GEODE.md + .geode/skills/는 런타임 문맥 · 권한·샌드박스는 호스트가 집행

워크트리의 수명, 격리에서 병합·회수까지



병합 결과 불확실 → 원격 상태 확인까지 재시도·회수 보류

실험 진입

검증한 SHA·입력·정책을 동결하고 admission을 통과하면 실행 가능. main 승격은 별도 승인 경로.

판정은 빨랐는데, 한 작업은 왜 더 걸렸을까?

○ LLM ■ Jev 선 하나 = 같은 과제·반복의 한 쌍

최종 판정 호출 · 초

explicit · r0


explicit · r1

context · r0 *

context · r1

korean · r0

korean · r1



판정 중앙값: 7.235초 → 0.426초

판정은 빨랐는데, 한 작업은 왜 더 걸렸을까?

○ LLM ■ Jev 선 하나 = 같은 과제·반복의 한 쌍

최종 판정 호출 · 초

explicit · r0

explicit · r1

context · r0 *

context · r1

korean · r0

korean · r1

0

4

8

12

판정 중앙값: 7.235초 → 0.426초

GEODE 실행 시간 · 초 (준비·검증 제외)

0

20

40

60

runtime 중앙값: 50.198초 → 46.439초 · 양쪽 6/6 통과

판정은 빨랐는데, 한 작업은 왜 더 걸렸을까?

context · r0 · 막대: 호출 시간 · 우측: runtime(잔여 포함, 초)

LLM 군	메인 8.02	Reflection 18.26	메인 17.27	판정 6.51	50.46초
Jev 군	메인 7.89	Reflection 15.97	메인 18.60	Reflection 7.88	판정 0.43
				판정 전에 한 번 더 · +7.88	51.19초


판정 -6.07 · 추가 Reflection +7.88 · 첫 Reflection -2.29 · 메인 +1.21 · 잔여 +0.01 → 전체 +0.74초

판정 직전의 추가 Cognitive Reflection: +7.88초. 해당 판정 호출의 절감 6.07초를 초과.

주기 규칙: Astra Cognitive confidence ≥ 0.8이면 간격 2배. 기록값은 LLM 0.8, Jev의 추가 Reflection 직후 0.65. 첫 Reflection의 confidence는 미기록이므로 추가 호출의 원인은 미확정.

판정 6회 합계는 18.2배 차이, 전체 시간은?

여섯 쌍 합계 · Jev – LLM · 초 · 자연 실행 r2 natural (inbox 3개 × 2반복)



나머지 구간이 같다는 가정: 판정이 0초일 때의 단축 상한 14.95% · 배수 = LLM ÷ Jev

판정 -43.264초 + 나머지 구간 +13.485초 = 전체 -29.779초 (-9.72%)

호출 순서: 12개 실행 모두 메인 에이전트 종료 후 판정. 판정 이후 재요청 0건.
증가분의 관측 위치: Jev 호출 전 Astra 실행 구간.
korean/r1에서 +10.5초 · 입력 3,011토큰이 같은 첫 호출도 9.6 → 14.3초 · 두 호출 출력 합 512 → 723토큰

같은 답에 다른 관측을 주면?

고정된 요청과 완료 후보 “A-104는 발송됐습니다”. 비교 변수는 도구 관측 3종.

입력한 관측	LLM Jev · 실제 판정	코드가 만든 예상 분기
<code>status: shipped</code> 같은 완료 후보를 뒷받침	<code>supported supported</code> Jev confidence 1.00	통과 → 수정 없음
<code>status: cancelled</code> 같은 완료 후보와 모순	<code>contradicted contradicted</code> Jev confidence 1.00	미통과 → 수정 요청
<code>observations: []</code> 후보를 검증할 근거가 없음	<code>insufficient_evidence insufficient_evidence</code> Jev confidence 0.95	미통과 → 수정 요청

진단 범위 두 엔진 모두 기대 라벨 3/3 일치. 수정 분기는 코드 투영값이며, 이 진단의 후속 에이전트 호출은 0회.

근거 부족에 돌아온 ‘모순’ 판정

동일 입력 · A-104 후보: shipped · 조회 관측: 0건

LLM Astra / xhigh

요청 계약 · Astra에 요구한 필드: verdict 1개

실제 반환

```
{"verdict": "insufficient_evidence"}
```

응답 지연 6.607초 · 입력 929 / 출력 106토큰

...step-2-025475da

실행 영향 Jev는 insufficient_evidence 대신 contradicted를 선택. 두 라벨의 공통 처리 규칙에 따라 완료를 보류하고 수정 경로로 분기.

Jev Jev 1.13

요청 계약 · Choice 프리미티브

실제 반환


```
{"verdict": {  
  "type": "choice", "choice": "contradicted",  
  "confidence": 0.58,  
  "probabilities": {"supported": 0.0,  
    "contradicted": 0.72,  
    "insufficient_evidence": 0.28}  
}}
```

응답 지연 8.506초 · 입력 933 / 출력 51토큰

...step-2-a1a1d069

첫 미통과부터 복구까지의 비용

조회 전: 답은 shipped로 맞았지만, 기록된 조회 근거는 0개



답: shipped → shipped · 새로 확보한 조회 결과가 같은 답을 뒷받침

첫 미통과 판정 이후의 복구 구간	LLM	Jev
재계획 + 메인 에이전트 + Cognitive + 재판정	1 + 2 + 2 + 1	1 + 2 + 2 + 1
최종 판정 완료까지 걸린 시간	58.855 s	50.321 s
기록된 입력 / 출력 토큰	8,003 / 1,405	8,030 / 1,363
Astra API 환산액 / Jev 요율 계산액	\$0.150280 / Jev 미사용	\$0.135560 / \$0.000044058

confidence를 읽었다면, 무엇이 걸렸을까?

Jev 판정 13건의 confidence 순서. 실행에는 라벨만 사용, confidence는 관측 기록.

● 독립 검사와 일치

○ 불일치

자연 실행 비교

과제 verifier · 6건

고정 입력 판정


기대 라벨 · 3건

오류 주입 첫 판정

기대 라벨 · 2건

오류 주입 재판정

oracle · 2건



사후 진단

사후 경계 0.60 미만: 오답 1건 + 정답 2건. 오답 1건 검출에 재검토 3건.

정책 채택 전 조건: 별도 과제에서 이 사후 경계의 효용 검증

주문 A-104 상태 조회 · Choice

LLM verdict | Astra | 1x | 588a1c8 | replay 00:00:00.000

```
[reconstructed] Harbor ATIF replay; not a raw PTY capture.
[task] Process every inbox item.
<inbox>[{"id": "status_one", "request": "What is the current status of A-104?", "candidates": ["A-104"]}]/>
```

POST-RUN ORACLE: PASS | separate verifier receipt

Jev verdict | Astra | 1x | 588a1c8 | replay 00:00:00.000

```
[reconstructed] Harbor ATIF replay; not a raw PTY capture.
[task] Process every inbox item.
<inbox>[{"id": "status_one", "request": "What is the current status of A-104?", "candidates": ["A-104"]}]/>
```

POST-RUN ORACLE: PASS | separate verifier receipt

주문 A-104 상태 조회 · Choice

LLM verdict Astra 1x 588a1c8 replay 00:01:10.267	END	Jev verdict Astra 1x 588a1c8 replay 00:00:50.133	END / held
[reconstructed] Harbor ATIF replay; not a raw PTY capture. [task] Process every inbox item. <inbox>[{"id": "status_one", "request": "What is the current status of A-104?", "candidates": ["A-104"]}] \$ [lookup_order_status] {"items": [{"id": "status_one", "order_id": "A-104"}]} {"result": {"items": [{"id": "status_one", "order_id": "A-104", "status": "shipped"}]}} [agent] {"items": [{"id": "status_one", "order_id": "A-104", "status": "cancelled", "disposition": "answered"}]} [agent] {"items": [{"order_id": "A-104", "status": "shipped", "disposition": "answered", "id": "status_one"}]}		[reconstructed] Harbor ATIF replay; not a raw PTY capture. [task] Process every inbox item. <inbox>[{"id": "status_one", "request": "What is the current status of A-104?", "candidates": ["A-104"]}] \$ [lookup_order_status] {"items": [{"id": "status_one", "order_id": "A-104"}]} {"result": {"items": [{"id": "status_one", "order_id": "A-104", "status": "shipped"}]}} [agent] {"items": [{"id": "status_one", "order_id": "A-104", "status": "cancelled", "disposition": "answered"}]} [agent] {"items": [{"order_id": "A-104", "status": "shipped", "disposition": "answered", "id": "status_one"}]}	

CONTROLLED INPUT: {"items": [{"id": "status_one", "order_id": "A-104", "status": "cancelled", "disposition": "answered"}]}

Judgment 2: supported | 5311.9 ms

CODE FEEDBACK: Confirm the final response retains those evidence boundaries.

Feedback consumed: step-2-53687a5a (confirmed at call end)

POST-RUN ORACLE: PASS | separate verifier receipt

원본 재생 종료 · 결과 읽기

Replay ended · reading the results

그 판정 확률을 얼마나 믿을 수 있을까?

RLHF

응답 사이의 사람 선호

목표: 선호받는 응답

RLVR

정답·테스트로 검증한 보상

목표: 검증 기준 충족

RLCD

세부 학습 신호 미공개

목표: 판정 확률의 보정

RLCD의 공개 목표: 제시한 확률과 반복 평가에서 관측한 실제 정답 빈도의 일치.

그 판정 확률을 얼마나 믿을 수 있을까?

RLHF

응답 사이의 사람 선호

목표: 선호받는 응답

RLVR

정답·테스트로 검증한 보상

목표: 검증 기준 충족


RLCD

세부 학습 신호 미공개

목표: 판정 확률의 보정

RLCD의 공개 목표: 제시한 확률과 반복 평가에서 관측한 실제 정답 빈도의 일치.

외부 측정 · 확률이 높을수록 실제로 맞았나 (JEV-as-a-Judge, CMU 2026-09-22)



외부 논문의 측정값. GEODE 패널의 보정·오류 구분: 별도 본 실험의 평가 대상.

상태·행동을 잇는 CLM의 대조학습


대응하는 입력

고정된 기반 모델


학습하는 부분

대조학습 · InfoNCE


state



Qwen3-8B
last-token pooling





state head




state ↓

action



action head



action →

+		
	+	
		+

행·열에서 대응쌍의 확률을 높임
개념도 · 실측 점수 아님

디코더 기반 모델 → 입력 벡터 · head 학습 → 상태·행동의 유사도

학습 범위

공개 학습기의 정답은 기록된 상태·행동 대응쌍. 높은 유사도가 실제 과제 성공으로 이어지는지는 별도 평가.


반복 후보에서 다시 쓰는 행동 벡터

먼저 계산

고정된 후보들

Qwen → action head

벡터 재사용



scaled cosine

$\cos(s, a_i)$

$\vdots$

$\cos(s, a_n)$

→ softmax

→ 후보 확률분포

$P(a_i | \text{pool})$

$\dots$

주어진 후보 안에서


판단마다 계산

새 상태 + 질문

Qwen → state head

재사용 조건: 동일한 후보 문장·전처리·기반 모델·head

새 벡터



같은 s 로 각 후보 비교

비교 단위

저자 지연 수치는 후보 캐시를 준비한 뒤의 판정 시간. GEODE 비교에는 첫 후보 준비·반복 판정·오분류 뒤 복구를 함께 포함.

저자 warm-cache 결과: 후보 1,024개에서 44 ms / 579 ms · 로컬 CLM / hosted Jev

상태 200토큰 · 후보당 15토큰 · RTX 4090 · 5회 · 첫 후보 준비 비용 제외

판단 모델은 교체, 실행 주체는 유지

비교 설계 · 고정 입력 평가와 실제 실행을 구분

무엇을 바꾸고 무엇을 고정했나?

고정 입력의 판단과, 그 판단을 소비한 실제 실행의 분리

바꾸는 부분
판단 모델

○ A · GPT-6 Astra

Codex 구독 · effort xhigh

■ B · Jev 1.13.0

Direct API · 타입별 응답

고정 입력 비교

같은 상태·후보 풀·요청, 같은 과제별 평가 기준

Source · spec · 입력 · 정책 · budget: 각 실행 전에 고정

E2E의 실행 주체

양측 모두 Astra xhigh / GEODE

도구 사용·수리는 root의 역할. 중간 관측과 경로는 실행마다 달라질 수 있음.

최종 성공의 근거

별도 task verifier의 검사 + 실행 경로·관측 기록

판단 모델의 승인 ≠ 최종 과제 성공 · 공급자별 prompt 바이트까지 같다는 뜻은 아님

도입자의 완료 기준과 verifier의 검사 계약

도입자 설계 안내 · 이번 진단의 기준

어떤 관측을 완료의 증거로 인정할까?

업무의 완료 상태부터, 관측 가능한 검사까지

도입자가 정할 것	그 결정을 검증할 증거	기준을 설계하는 방법
● 완료된 산출물	무엇이 반환·저장·변경되어야 하는가?	실제 정상 사례에서 완료 조건 추출
● 허용하지 않을 오류	잘못된 대상·근거 없는 완료·무권한 변경	오류 비용에 따른 보류·거부 조건
● 성공 기준과 자원 한도	verifier·시간·비용·재시도 기록	경계 사례 검토 후 임계값 동결

도입자를 위한 설계 안내. 이번 실험의 임계값은 업무 SLO나 보편적 안전 기준이 아님.

도입자의 완료 기준과 verifier의 검사 계약

도입자 설계 안내 · 이번 진단의 기준

어떤 관측을 완료의 증거로 인정할까?

이번 과제: 읽기 전용 inbox의 모든 항목을 최종 JSON으로 반환

실제 고객 발송·주문 변경이 아닌, 고정 합성 과제의 sandbox 완료 조건

상태 요청	대상 주문 조회 → 관측을 읽고 답변
ID 없음·여러 주문	needs_clarification
취소·환불	unsupported · 변경 도구 없음
최종 형식	입력 ID마다 items 항목 한 개



Canonical	유효 시행 + 사후 검사 통과 + 실행 중 최종 승인
Strict	Canonical + 지정 helper 경로·소비 + 오조회·불필요 조회·거짓 완료 0

Helper 초기 정확도 ≠ 최종 완료. Root의 원 요청 재검토·helper 오류 교정 가능.

도입자의 완료 기준과 verifier의 검사 계약

도입자 설계 안내 · 이번 진단의 기준


어떤 관측을 완료의 증거로 인정할까?

두 순서 응답에서 한 풀의 정답 기여까지

Jev의 보존된 두 순서 응답을 결합한 한 풀 · 채점 방법을 보여주는 실제 사례

형식·수치 validator: 응답 유효성 검사. 정답 여부의 채점은 별도.

후보 ID별 두 순서 평균



평균이 가장 높은 후보

A
argmax = A
2.325

모델 실행 전 정한 등급

A: 3 B: 0 C: 2 D: 0

선택 A의 grade = 3

최고 grade와 일치

1 / 1 이 풀의 정답 기여

정순·역순은 한 풀의 측정이며 독립 표본 2개가 아님. 동률은 동결한 hash 규칙으로 처리.

같은 원천의 항목을 묶어 재표집. 정확도 차이의 불확실성을 95% 구간으로 표시.

Score의 모델 형식 오류·fallback은 원분모 안의 0점. 인프라 무효·미실행은 성능 0과 구분.

Pointwise 본비교의 한 사례. Listwise 참조군의 채점 단위: 두 순서 정답의 평균, 0 / 0.5 / 1.

자료별 측정 질문과 비교 단위

최종 native 근거 · 편집 해석

이 숫자는 항목 수인가, 독립 과제 수인가?

서로 다른 분모, 분리된 성공률

원천 / 저작	가시성 / 분할	분모 / 독립 단위	Gold 소유
저작 판정 패널 45 source clusters	Selection 18 · Test 27 공개 입력 · 정답 분리	160 / 240 states 주 분석 Test 216	규칙 oracle Test 개봉 후 대조
I · 의도·대상 설계자 저작	비봉인 진단 자료 Admission 4 · Main 40 families	20 / 220 items E2E 36항목 ≠ 3과제	저작 라벨 Held-out 아님
E · inbox 과제 패널과 별도 · 20과제	자연 12 + 주입 6 + 예비 2 Arm별 새 컨테이너	U7: 12 tasks × 3 × 2 U8c: 6 tasks × 3 faults × 2	독립 verifier 판정 모델과 분리
외부 X1 / X2 사람 라벨 / Mind2Web	텍스트 변환 / 4후보 선택 X2: 공식 split별 80	239 states / 240 pools 133 / 94 clusters	원천 Gold 유지 전 시행 후 채점

상태·항목·후보 풀·과제·호출별로 다른 분모. 성공률은 같은 측정 단위 안에서 비교.

자료별 측정 질문과 비교 단위

최종 native 근거 · 편집 해석

이 숫자는 항목 수인가, 독립 과제 수인가?

같은 원천의 상태는 어떻게 한 묶음으로 처리했나?

판정 패널 · 45 source clusters	Score · 80 controlled pools
----------------------------	-----------------------------

Selection 18 / 160상태

주 분석 144 + 범위 밖 16

Test 27 / 240상태

주 분석 216 + 범위 밖 24

40:60 = source cluster 수의 비율. 무작위 배정의 증거는 아님.

공개 형제 상태를 통한 m 조건 복원 가능. 완전한 blind 조건은 아님.

Selection 32 + Test 48

80개 전체가 held-out인 것은 아님

자연 후보 12풀 · best-of-4

생성 뒤 고정 · 다시 뽑아 성공시키지 않음

모순과 근거 누락을 분리한 2×2 설계

완료 판정 패널 · 구조화된 상태의 통제 변형

모순과 근거 누락을 따로 검사할 수 있나?

한 원천의 claim · observation · contract에서 두 요인을 독립 조작

c · 요청·계약·관측과의 모순			
		c = 0 · 없음	c = 1 · 있음
m · 필수 근거 m = 0 충족	두 결함 모두 없음 c0m0		
	근거만 누락 c0m1		
m = 1 누락	모순만 있음 c1m0		
	모순과 근거 누락 c1m1		

90 × 4 = 360

2×2 묶음 90개 · 주 분석 상태

+ 40

범위 밖 진단 상태

= 400

Selection + Test 전체 상태

독립 묶음은 45 source clusters. 같은 원천의 네 상태를 독립 표본 네 개로 취급하지 않음.

정답의 근거

Rule oracle

설계한 조건·변형 규칙과 대조

모델 응답은 평가 대상


gold 생성에 사용하지 않음

실제 업무 정답의 인간 전수 검증과 별도

누가 어떤 증거를 읽어 다음 단계를 허용하는가

최종 native 근거 · 편집 해석

누가 기록을 만들고, 누가 검증하나?



점수의 권위: native 결과와 verifier. 재생.영상은 실행 확인용 근거.


실험 트랙별 선행 조건과 분석 단위

최종 native 근거 · 편집 해석

진입 점검 통과와 본 측정 성공은 같은가?

P · 완료 판정 / 보정 / 반복 일관성 / 지연

9개 등록 단위. 실선은 선행 조건, 동시 실행 표시는 아님.



시행 종료 ≠ 분석 완료

고정 분석의 진입 조건: U2·U2s·U3 전체 종료 + 명시적 개봉 승인


실험 트랙별 선행 조건과 분석 단위

최종 native 근거 · 편집 해석

진입 점검 통과와 본 측정 성공은 같은가?

G/P · 후보 선택 / P · 의도 / X · 외부 전이

9개 등록 단위. X의 실행 경로는 공통 P driver.



X 공통 gate: 핵심 P 종료·개봉·운영 순서. 외부 정답 접근은 해당 attempt 종료 후.
U5의 비변별 풀도 원형 보존. 선택 성공을 위한 후보 재생성 없음.

실험 트랙별 선행 조건과 분석 단위

최종 native 근거 · 편집 해석

진입 점검 통과와 본 측정 성공은 같은가?

E · 실제 과제, 복구, 의도 전달, C 반복

9개 등록 단위. 후속 실행 조건: 같은 source의 admission·감사·위임 재생.




C 진입 조건: frozen τ · U2c gate · 명시적 C / budget 승인. 27개 ID ≠ 모델 승패 수.

Selection에서 정책 동결, 실행 종료 후 정답 개봉

최종 native 근거 · 편집 해석

정책은 언제 고정하고, 정답은 언제 열었나?



Choice T: Astra 8 / Jev 1.4 · $\tau=0.50$. T = 사후 확률 보정값, 생성 temperature와 별도.

AUROC·C의 입력: raw q=max P. 별도 native Confidence 필드와 구분.

Selection에서 정책 동결, 실행 종료 후 정답 개봉

최종 native 근거 · 편집 해석

정책은 언제 고정하고, 정답은 언제 열었나?



공개 형제 상태의 m 조건 복원: 216/216. 모델 입력은 매 호출 단일 상태.
Test를 이용한 T·τ 재적합 없음. 해시·접근 규칙 ≠ 암호화·OS 격리.

숫자를 읽기 전, 지표가 답하는 질문

용어 해설 · 새 실험 결과 아님

단위·방향·판정 기준부터

비교 도표 · 차이와 불확실성

Δ · pp	두 조건의 정답률은 얼마나 다른가? $\Delta = J_{ev} - A_{stra}$. pp는 퍼센트포인트 차이, 상대 변화율 %와 구분.
95% CI	차이의 추정치는 얼마나 불확실한가? 관련 항목을 원천별로 함께 재표집한 추정 구간. 개별 응답의 확률은 아님.
NI · margin	미리 허용한 손실 범위 안인가? 이 연구의 기준: CI 하한이 -5 또는 -10 pp보다 높아야 충족. 업무 SLO와 별도.
Source cluster	무엇을 서로 독립된 근거로 썼나? 같은 원천의 관련 상태를 한 묶음으로 처리. 호출 수를 독립 표본 수로 쓰지 않음.

숫자를 읽기 전, 지표가 답하는 질문

용어 해설 · 새 실험 결과 아님

단위·방향·판정 기준부터

확률 신호 · 보정, 오류 구분, 선택적 수락

ECE ↓

낮을수록 좋음 · 추세 아님

제시한 확률과 실제 정답률은 얼마나 맞는가?

유효 응답의 확률 구간별 평균 확률과 정답률의 절대 차이를 표본 수로 가중.

AUROC ↑

높을수록 좋음 · 추세 아님

틀릴 응답을 먼저 구분하는가?

이 연구는 $1-q$ 로 오답을 정답보다 앞에 두는지 측정. 0.5는 무작위 순위 기준.

Coverage / Risk

얼마나 수락했고, 수락한 것 중 얼마나 틀렸나?

Coverage = 수락 / 계획 전체. Risk = 수락한 오답 / 수락 전체.

AURC ↓

낮을수록 좋음 · 추세 아님

수락 범위를 넓힐 때 오답 부담은 얼마나 커지나?

Risk–coverage 곡선 아래 면적. 낮을수록 작은 오답 부담, 완전한 안전 보장은 아님.

숫자를 읽기 전, 지표가 답하는 질문

용어 해설 · 새 실험 결과 아님

단위·방향·판정 기준부터

반복과 실행 · 성공, 실패, 측정 가능성

pass@1 / @2 / ^2	한 번의 성공, 한 번 이상, 두 번 모두 중 무엇을 보나? 이번 실행: 시행당 평균 / 두 반복 중 ≥ 1회 / 두 반복 모두. 후보 4개 선택과 별도.
canonical / strict	완료를 넘어서 지정 경로·조회 조건까지 지켰나? Canonical: 유효 실행·사후 검사·최종 승인. Strict: 지정 경로·조회·반환 조건까지 추가.
Failure / Invalid	모델의 실패인가, 측정 근거가 성립하지 않았나? 유효 오답은 관측 결과. 인프라 무효·미실행은 0% 성과와 별도. 출력 오류는 지표 규칙 적용.
Admission / Test	경로의 사전 점검인가, 본 측정의 성능인가? Admission은 후속 실행의 진입 조건. 통과 수치를 본 실험의 성공률에 합산하지 않음.

평균 차이 -0.93 pp, 넓은 추정 구간

측정 완료 · 원결과 보존

정확도 손실은 사전에 허용한 범위 안인가?

Choice · 주 분석 216상태

A · Astra xhigh

157/216

B · Jev 1.13.0

155/216

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p$ (pp)

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

점선: NI -5 pp

 $\Delta -0.93 \text{ pp} \cdot 95\% \text{ CI } [-9.72, +7.41]$

평균 차 -0.93 pp · 넓은 CI로 -5 pp 비열등성은 입증하지 못함

4×4 순서 교대 · 모델 무효1건도 오답 · 27원천 군집 bootstrap 2,000회

두 조건의 joint 정확도, -41.67 pp

패널 완료 · 기존 source5 Harbor 후속: 미실행 종결

두 조건을 함께 맞혔나?

Noul · 모순·근거 누락 두 조건을 모두 맞힌 비율

A · Astra xhigh

145/216


B · Jev 1.13.0

55/216

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p \text{ (pp)}$

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

점선: NI -5 pp

$\Delta -41.67 \text{ pp} \cdot 95\% \text{ CI } [-48.15, -35.19]$

조건별 정답: 모순 A154 / B131 · 근거 누락 A207 / B108 (각 216상태)

조건별 정답과 joint는 별도 · CI 전체가 -5 pp 아래 · 27원천 군집 재표집 2,000회

고정 의도·대상 분류, -1.82 pp

의도·대상 패널 · 220항목 / 40가족

의도와 대상이 모두 맞은 항목은 몇 개인가?

의도와 대상 joint · 220항목 / 40계열

A · Astra xhigh

220/220

B · Jev 1.13.0

216/220

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p$ (pp)

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

점선: NI -5 pp

 $\Delta -1.82 \text{ pp} \cdot 95\% \text{ bootstrap CI } [-3.65, -0.45]$

CI 하한이 -5 pp 위: 패널 내 비열등성 충족 · 일반화 근거는 아님

설계자 저작 패널 · 40가족 단위 percentile bootstrap 2,000회

후보 선택 정확도와 후보 풀의 변별력

보존 응답의 사후 교정 분석

가장 높은 oracle grade의 후보를 골랐나?

Score · 통제 후보 top-1 정확도

A · Astra xhigh

79/80

B · Jev 1.13.0

59/80

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p \text{ (pp)}$

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

점선: NI -10 pp

$\Delta -25.00 \text{ pp} \cdot 95\% \text{ CI } [-35.23, -16.25]$

CI 전체가 -10 pp 아래 · 이 후보 구성에서 Jev 선택 정확도가 낮음

새 호출 없이 수치 경계 처리 교정: Jev 58→59/80 · 분모·grade·45 clusters 유지

후보 선택 정확도와 후보 풀의 변별력

보존 응답의 사후 교정 분석

가장 높은 oracle grade의 후보를 골랐나?

자연 후보 12풀 · best-of-4	정답 선택	gap_closed
Astra pointwise	12/12	측정 불가
Jev pointwise	12/12	측정 불가
First / random / oracle	모두 12/12	변별력 없음

gap_closed: 무작위 선택보다 oracle에 얼마나 가까워졌나?
분모 oracle coverage – random = 0 · 선택 정확도 $\Delta = 0$ pp · 동등성·우월성 미입증

Astra가 한 번 생성한 고정 후보 · 추가 생성·선택 우월성 주장 없음

더 높은 상대 정확도, 여전히 많은 성공 거부

측정 완료 · 원결과 보존

실패를 잡으면서 정상 완료도 거부하지 않았나?

CUAVerifierBench · 다른 저작자, 사람 라벨

수작업 패널 밖에서도 판정 방향이 유지되는지 검사

260상태 – 사람 동률 21 = 239상태

133 source clusters · 원본 benchmark 점수와 분리

Actions · thoughts · notes의 텍스트 변환

입력에서 제외: Screenshot·실제 tool 결과 내용

Policy는 내부 selection에서 정한 그대로

외부 Test를 이용한 T·τ 재적합 없음

원 궤적의 사람 라벨과 축소된 텍스트 입력을 대조 · 실제 컴퓨터 사용 성공률 아님

더 높은 상대 정확도, 여전히 많은 성공 거부

측정 완료 · 원결과 보존

실패를 잡으면서 정상 완료도 거부하지 않았나?

외부 텍스트 상태의 이진 판정

A · Astra xhigh

125/239

B · Jev 1.13.0

136/239

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p$ (pp)

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

NI 기준선 없음

 $\Delta +4.60$ pp · 95% CI [+0.41, +9.36]

성공 거부: A113/119 · B97/119 | 실패 수락: A1/120 · B6/120

정답 11건 증가 = 성공 거부 16건 감소 - 실패 수락 5건 증가 · 입력 축소의 원인 효과는 미검증

같은 네 후보에 대한 선택 정확도 차이

보존 응답의 사후 교정 분석

한 단계의 선택인가, 전체 웹 과제의 완료인가?

세 test split

cross-task / website / domain

통제 후보 K = 4


정답 1 + 오답 3 · 두 순서

Score 선택

cross-task



cross-website



cross-domain



240 step · 세 split에 각 80개

전체 웹 탐색의 완료율이 아닌, 한 단계의 후보 선택

후보 구성 규칙이 난이도를 결정 · 원래 전체 후보 순위와 구분

화면에는 변환 구조·ID·해시만 · 문항 원문·HTML 비공개

외부 데이터로 임계값·평가 기준을 조정하지 않음

같은 네 후보에 대한 선택 정확도 차이

보존 응답의 사후 교정 분석

한 단계의 선택인가, 전체 웹 과제의 완료인가?

Mind2Web · 같은 4후보, 240 step

A · Astra xhigh

226/240

B · Jev 1.13.0

196/240

정확도 차이 $\Delta = \text{Jev} - \text{Astra} \cdot \%p \text{ (pp)}$

음수: Jev 정확도가 낮음

양수: Jev 정확도가 높음



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

점선: NI -10 pp

$\Delta -12.50 \text{ pp} \cdot 95\% \text{ CI } [-17.22, -8.04]$

CI 전체가 0 아래, -10 pp를 가로지름 · 등록 마진의 실무 허용 근거는 약함

새 호출 없이 수치 경계 처리 교정: Jev 194→196/240 · 분모·grade·94 clusters 유지


같은 판정에서 더 짧은 응답 대기시간

측정 완료 · 원결과 보존

같은 입력의 판정 호출은 얼마나 빨리 끝났나?

120쌍에서 관측한 응답 시간 분포

세로축: 해당 시간 안에 응답한 비율



Astra · xhigh

10.446 s

Median · 120회

Jev · 1.13.0

0.253 s

Median · 120회

측정 범위: verifier 호출의 대기시간. GEODE 전체 작업 시간과 별도.

같은 판정에서 더 짧은 응답 대기시간

측정 완료 · 원결과 보존

같은 입력의 판정 호출은 얼마나 빨리 끝났나?

동시 dispatch · 120/120 비교 가능 쌍

동시 호출 쌍

120

Source clusters

27

쌍별 B-A 지연 차이의 median · 초

음수: Jev 판정이 빠름

양수: Jev 판정이 느림



점: 차이 추정 · 95% CI: 차이의 불확실성

실선 0: 차이 없음

NI 기준선 없음

Δ -10.20 s · 95% CI [-11.34, -8.81]

판정 지연 차이의 불확실성 · 개별 호출 분산이나 전체 작업 시간 아님

$\text{median}(B_i - A_i)$ · $\text{median}(B) - \text{median}(A)$ 가 아님 · 27 source clusters

호출 지연과 과금 비용의 분리

E7 U7r1 이후 원장 · 2026-09-28 00:34 KST

추정 비용과 실제 청구를 구분했나?

기록된 호출 · 요율 기반 추정 · 실제 청구의 구분

기록된 호출

Astra 3,753 · Jev 2,267

실패·중단·복구 호출 포함

Jev 사용량

5,324,918 input tokens

known 2,263 · unknown 4 calls

\$0.223646556

입력 단가 기반 추정

\$0.004200000

unknown 사용량 예약

unknown

실제 invoice

Committed \$0.227846556 · 운영 cap \$2.35. 실제 소비·청구액과 별도.

Astra 구독 사용을 PAYG 절감액으로 환산 불가. 전체 물리 호출 coverage는 unknown.


Noul·Jev: 응답 일치 23/24, 두 번 모두 정답 6/24

24상태 반복 진단 · 원결과 보존

같은 응답이 반복되나, 정답이 반복되나?

각 primitive의 24상태 · 같은 입력을 새로 두 번 호출

비용·지연 다음 질문: 빠른 응답이 반복될 때도 정답인가?



Noul·Jev: 23/24의 일관성, 두 번 모두 정답은 6/24. 동일한 오답도 일관성에 포함.


Noul·Jev: 응답 일치 23/24, 두 번 모두 정답 6/24

24상태 반복 진단 · 원결과 보존

같은 응답이 반복되나, 정답이 반복되나?

의미를 유지한 입력 변형 · Jev 응답이 달라진 상태 수

순서 반전과 paraphrase를 각각 원응답과 비교 · 같은 입력의 두 반복과는 별도



낮은 flip은 입력 변형에 덜 민감하다는 관측. 높은 정답률이나 E2E pass²의 증거는 아님.


다음: 반복 일관성과 별개로, 응답 확률이 오답을 구분하는지 검사

판정 확률은 오류를 얼마나 가르는가

측정 완료 · 원결과 보존

확률의 보정과 오답 구분은 같은 능력인가?

Raw q = max P 순서의 coverage와 error risk



q 내림차순 수락 · Coverage: 수락 수 / 전체 216상태 · Risk: 수락 중 오답률

판정 확률은 오류를 얼마나 가르는가

측정 완료 · 원결과 보존

확률의 보정과 오답 구분은 같은 능력인가?

같은 확률 신호를 서로 다른 질문으로 평가

	Astra · xhigh	Jev · 1.13.0
Raw ECE ↓ 제시한 확률과 실제 정답률은 얼마나 맞는가?	0.260	0.075
Calibrated ECE ↓ Selection에서 보정한 뒤 불일치는 얼마나 남았나?	0.109	0.077
AUROC ↑ 틀릴 응답을 먼저 구분하는가?	0.879	0.785

이 패널: ECE는 Jev가 낮고, AUROC는 Astra가 높음 · 하나의 우열 점수로 합산 불가
ECE: 10개 동일 폭 구간 · AUROC: 1-q로 오답 탐지 · q=max P ≠ native Confidence 필드
Astra 216 · Jev 215 valid 확률 · T: 8.0 / 1.4, Selection에서 동결


조건부 수락 정책과 Astra 재검토

Selection에서 동결한 $\tau=0.50$

어떤 응답을 채택하고, 언제 재검토로 넘기나?

Jev 응답

$q = \max P \cdot \text{응답 중 최대 확률}$



Selection에서만 τ 결정 → Test에서 동일 정책 평가

Jev의 confidence와 q 를 같은 값으로 취급하지 않음

유효성· q 조건을 충족한 응답만 Jev 결정 채택. 나머지는 Astra의 별도 판정.

조건부 수락 정책과 Astra 재검토

Selection에서 동결한 $\tau=0.50$

어떤 응답을 채택하고, 언제 재검토로 넘기나?

패널의 조건부 수락 정책

Astra · xhigh

157/216

Jev coverage 190/216 · $\tau = 0.5$

$\Delta +1.39\%_p$ · 95% CI $[-6.48, +9.26]\%_p$

같은 Test 응답으로 계산한 조건부 정책

패널의 응답 선택 결과이지, 실행 중 fallback 관측 횟수가 아님

CI가 0을 포함 · 정확도 우월성 미입증. 실행 중 전환의 효용은 별도 검사 대상.

Jev + Astra fallback

160/216

슬롯 안의 비교 실행, 슬롯 사이의 종료 확인

최종 native 근거 · 편집 해석

한 과제의 비교 조건들이 같은 규칙으로 시작했나?

단위 사이에는 전역 잠금, 한 슬롯 안에는 격리된 Arm



Dispatch >1초: 인프라 무효 · agent-start skew >30초: paired latency 제외

시작 동기화와 의미적 성공은 별도. U7 r1의 2쌍도 strict/reliability 분모에 유지.

최종 조건의 자연 실행: 세 정책 모두 완료

최종 native 근거 · 편집 해석

한 번 성공했나, 두 반복 모두 성공했나?

독립 과제 12개 · 조건 3개 · 처음부터 다시 실행한 두 반복

채운 점 하나 = 한 과제의 strict 성공 · 열은 반복, 행은 완료 verifier 정책

	반복 1		반복 2
A · Astra	12/12		12/12
B · Jev	12/12		12/12
C · 조건부 위임	12/12		12/12

72/72 완료 · 독립 과제는 12개

모든 조건: pass@1 = pass@2 = pass^2 = 12/12 · 시행당 평균 / 두 번 중 한 번 / 두 번 모두
C: 24수용·실제 fallback 0. 실행 완료는 확인, 포화된 성공률에서 정책 간 효용 차이는 미식별.

두 verifier의 오류 포착과 Astra의 수리

최종 native 근거 · 편집 해석

오류 발견 뒤 실제 수리와 완료까지 이어졌나?

결함 조합	수정해야 할 내용	완료 시행
모순만 있음	관측과 어긋난 답 교정	6과제 × A/B
근거만 누락	필수 근거 확보·반영	6과제 × A/B
모순 + 누락	두 문제 모두 한 수정 라운드에서 해소	6과제 × A/B

Choice 총 36시행 · 같은 결함 조합에서 A/B 쌍 비교

두 verifier의 오류 포착과 Astra의 수리

최종 native 근거 · 편집 해석

오류 발견 뒤 실제 수리와 완료까지 이어졌나?

실제 Choice 복구 · A/B 각 18시행

	A · Astra xhigh	B · Jev 1.13.0
첫 부정 판정	18/18	18/18
최종 복구 · strict 성공	18/18	18/18
시행당 Astra replan	1	1

36시행 모두: 부정 피드백 소비 → Astra 수리 → strict 완료 · 거짓 완료 0

18쌍 / 6원천 · 복구율 차이 0 · CI 없음 · 서술적 비교


쌍별 B-A runtime median -18.17 s · 모든 시행 180초 미만

계획된 결함 주입의 결과. 일반적 복구 신뢰도·resource budget의 인과효과와 별도.

주문 문의 12건 처리 · Choice

완료 후보 검증 · 결함 주입 뒤 수정과 최종 반환


A · Astra xhigh



클립 102.50초 · native runtime 101.60초

ATIF 파생 · 원 PTY/동시 실행 아님 · 영상 4배속/원본 시계 · 점수·지연은 native 결과 기준

B · Jev verdict · Astra root



클립 94.93초 · native runtime 94.03초

환불 완료 오주장과 누락된 조회 근거

source7 Noul 실행 · 사후 분석

verifier는 무엇을 근거로 후보를 확인했나?

12개 합성 문의 · 실행과 수리는 양측 모두 Astra xhigh

verifier에 전달한 네 입력

task_contract

읽기 전용 · 상태 조회 / 추가 확인 / unsupported

original_request

상태·환불·정정·복수 주문을 포함한 12개 문의

candidate_output

후보 JSON · 첫 후보는 통제 결함 주입

tool_observations

실제 lookup 입력과 결과 · 처음에는 없음

c: 요청·계약·관측과의 모순 · m: 필수 근거 누락

정답표·비공개 추론은 verifier 입력과 별도

처음 주입한 결함

요청 환불 · T-846

허용 동작 조회만 가능
 변경 도구 없음

주입 후보 **status: refunded**
 disposition: answered
 필수 조회 관측도 없음

첫 verdict **양측 c=1, m=1**
부정 feedback을 Astra가 소비

환불 완료 오주장과 누락된 조회 근거

source7 Noul 실행 · 사후 분석

verifier는 무엇을 근거로 후보를 확인했나?

Astra의 실제 조회 5건과, 계약에 맞춘 후보 JSON

한 lookup batch 안의 상태 조회 5항목 · 호출 5회라는 뜻은 아님

T-503	processing	환불 요청	unsupported status=null
T-218	shipped		
T-691	on_hold	조회 필요 5건	실제 조회와 일치
T-135	delivered	나머지 7건	unsupported 또는 needs_clarification
T-284	out_for_delivery		

12/12

양측 마지막 후보의 항목 정답 · 최종 전달 성공과는 별개

대응 사례의 의미상 항목·계약·조회 상태는 일치. JSON 표현과 호출 ID까지 바이트 동일하지는 않음.

Noul: 근거 충족 후보의 반환 보류


source7 Noul 실행 · 사후 분석

반환 차단 조건과 오거부의 원인은 어디까지 확인됐나?

필수 근거를 받은 Jev의 오거부, GEODE의 반환 보류

양측 후보 정답 12/12 · 조회 5건 충족. 거부를 유발한 항목·표현은 미식별.

P(필수 근거 누락)



모순(c): A 0.00 · B 0.38, 모두 0.50 미만

A: c=false / m=false · supported · JSON 반환

B의 반환을 막은 실행 조건

Jev 출력	m = 0.63 ≥ 0.50 c=false / m=true
어댑터 판정	insufficient_evidence passed=false
GEODE 정책	continuation budget 2/2 소진 정답 후보는 pending_text에 보존 최종 응답 text="" · 반환 보류

완료 후보를 다시 확인한 두 호출: m=0.60, 0.63 · 고정 과제 계약에 대한 오거부
Reflection은 GEODE 고정 문구, Jev의 설명 아님 · 항목별 거부 이유는 응답에 없음

Noul: 근거 충족 후보의 반환 보류

source7 Noul 실행 · 사후 분석

반환 차단 조건과 오거부의 원인은 어디까지 확인됐나?

양쪽 시행이 모두 유효한 11건의 비교 · 4개 원천

양측 마지막 후보 정답 11/11 · A strict/recovered 11/11 · B 0/11, 전달 보류 11/11


		A · Astra			B · Jev		
		모순만	근거 누락만	둘 다			
telescopes	3쌍	●	●	●	□	□	□
badminton	3쌍	●	●	●	□	□	□
waterpurifiers	3쌍	●	●	●	□	□	□
strollers	2쌍	●	●	-	□	□	-

채움: strict 완료 · 빈칸: 반환 보류 · -: B 시행 무효로 비교에서 제외
계획36 · 관측24(유효23 / 무효1) · 미실행12 · 원 실행 invalidated, primary null
별도 무효 1건: 예정한 결함 주입 누락으로 중단 · 유효한 B 시행 11건의 오거부와 구분

주문 문의 12건 처리 · Noul

필수 조회 5건 완료 · Jev의 근거 부족 판정으로 반환 보류


A · Astra xhigh



원본 영상 시각 · 과제 지연 측정과 별도

ATIF 파생 · 원 PTY/동시 실행 아님 · 영상 4배속/원본 시계 · 점수·지연은 native 결과 기준

B · Jev verdict · Astra root



원본 영상 시각 · 과제 지연 측정과 별도

최종 inbox 실행: 항목 판단부터 JSON 반환까지



계약 교정 전후의 결과를 별도 계보로 보존

Helper 정답과 최종 과제 완료를 따로 썼나?

최종 조건 · source7 · 항목 판단과 과제 완료의 분리

Helper · intent와 target 각각
군별 36항목 · initial = final

독립 과제 · strict 완료
군별 3시행 · 반복 1회



X: 정답 항목 수 (0–36)

채운 점 1개 = strict 성공 1시행

관측 3시행/군: 재판정·helper correction·오조화·거짓 완료 0

Δ strict = 0 pp · 3쌍 · CI 없음 · 서술적 비교, 우월·동등성 검정 없음

저자가 본 합성 inbox 3개 · 반복 1 · 실제 고객 발송이 아닌 최종 JSON 반환

한국어 문의 12건 분류 · Choice

의도·대상 분류 helper · 최종 verifier는 Astra

A · Astra xhigh

```
TASK PASS | ATIF-derived replay | NOT raw PTY | 1x | not latency evidence
A | Root Astra xhigh | Intent helper Astra xhigh
Display only - inbox entities decoded once - model request remains escaped

[reconstructed] Harbor ATIF replay; not a raw PTY capture.
[task] Process every inbox item.
<inbox>[{"id": "ko_one", "request": "C-318은 현재 배송 상태만 알려 주세요.", "candidates": [{"C-318"}], {"id": "ko_two", "request": "D-427은 취소하지 마세요. 도착했는지만 확인해 주세요.", "candidates": [{"D-427"}], {"id": "ko_three", "request": "F-645라고 잘못 적었습니다. 조희창 주장은 E-536입니다.", "candidates": [{"F-645"}, {"E-536"}], {"id": "ko_four", "request": "E-536은 몇몇 주문이고 F-645가 제 주문입니다. 각 주문 상태를 확인해 주세요.", "candidates": [{"E-536"}, {"F-645"}], {"id": "ko_five", "request": "G-754를 왕복해 달라는 뜻이 아닙니다. 현재 상태만 궁금합니다.", "candidates": [{"G-754"}], {"id": "ko_six", "request": "미모에는 'I-972 취소'라고 적혀 있지만 지금 요청은 H-863의 배송 조회입니다.", "candidates": [{"I-972"}, {"H-863"}], {"id": "ko seven", "request": "I-972를 취소해 주세요. J-881은 그대로 두세요.", "candidates": [{"I-972"}, {"J-881"}], {"id": "ko_eight", "request": "환불 받으려는 주문은 J-881입니다. I-972는 아닙니다.", "candidates": [{"J-881"}, {"I-972"}], {"id": "ko_nine", "request": "C-318과 D-427의 배송 상태를 둘 다 확인해 주세요.", "candidates": [{"C-318"}, {"D-427"}], {"id": "ko ten", "request": "주문번호를 잃어버렸습니다. 언제 배송되는지 알려 주세요.", "candidates": []}, {"id": "ko_eleven", "request": "친구에게 술 성일 선물을 추천해 주세요.", "candidates": []}, {"id": "ko_twelve", "request": "E-536은 취소한지 환불받는지 아직 잘하지 않았습니다. 지금은 아무것도 처리하지 마세요.", "candidates": [{"E-536"}]}</inbox>
```

클립 93.23초 · native runtime 92.55초

ATIF 파생 · 원 PTY/동시 실행 아님 · 영상 4배속/원본 시계 · 점수·지연은 native 결과 기준

B · Jev helper · Astra root

```
TASK PASS | ATIF-derived replay | NOT raw PTY | 1x | not latency evidence
B | Root Astra xhigh | Intent helper Jev 1.13.0
Display only - inbox entities decoded once - model request remains escaped

[reconstructed] Harbor ATIF replay; not a raw PTY capture.
[task] Process every inbox item.
<inbox>[{"id": "ko_one", "request": "C-318은 현재 배송 상태만 알려 주세요.", "candidates": [{"C-318"}], {"id": "ko_two", "request": "D-427은 취소하지 마세요. 도착했는지만 확인해 주세요.", "candidates": [{"D-427"}], {"id": "ko_three", "request": "F-645라고 잘못 적었습니다. 조희창 주장은 E-536입니다.", "candidates": [{"F-645"}, {"E-536"}], {"id": "ko_four", "request": "E-536은 몇몇 주문이고 F-645가 제 주문입니다. 각 주문 상태를 확인해 주세요.", "candidates": [{"E-536"}, {"F-645"}], {"id": "ko_five", "request": "G-754를 왕복해 달라는 뜻이 아닙니다. 현재 상태만 궁금합니다.", "candidates": [{"G-754"}], {"id": "ko_six", "request": "미모에는 'I-972 취소'라고 적혀 있지만 지금 요청은 H-863의 배송 조회입니다.", "candidates": [{"I-972"}, {"H-863"}], {"id": "ko seven", "request": "I-972를 취소해 주세요. J-881은 그대로 두세요.", "candidates": [{"I-972"}, {"J-881"}], {"id": "ko_eight", "request": "환불 받으려는 주문은 J-881입니다. I-972는 아닙니다.", "candidates": [{"J-881"}, {"I-972"}], {"id": "ko_nine", "request": "C-318과 D-427의 배송 상태를 둘 다 확인해 주세요.", "candidates": [{"C-318"}, {"D-427"}], {"id": "ko ten", "request": "주문번호를 잃어버렸습니다. 언제 배송되는지 알려 주세요.", "candidates": []}, {"id": "ko_eleven", "request": "친구에게 술 성일 선물을 추천해 주세요.", "candidates": []}, {"id": "ko_twelve", "request": "E-536은 취소한지 환불받는지 아직 잘하지 않았습니다. 지금은 아무것도 처리하지 마세요.", "candidates": [{"E-536"}]}</inbox>
```

클립 77.07초 · native runtime 76.25초

이번 결과로 정할 수 있는 위임 범위

최종 native 근거 · 편집 해석

이 관측으로 어디까지 말할 수 있나?

관측에서 도출한 적용 범위와 채택 조건

대상	관측과 해석	운영 판단·채택 조건
고정 의도 분류	Astra 220/220 · Jev 216/220; E2E 각 3/3	새 inbox·새 원천에서 확인
Choice 완료 판정	평균 차이는 작지만 CI가 넓음	품질 손실 허용치의 운영 근거
Noul · 전달	Astra 145/216 · Jev 55/216 사후 11쌍 · Jev 후보 정답 11/11 / 전달 0/11	현재 단독 대체를 지지하지 않음
조건부 C	E7 U7 두 반복: C 24수락 / 0fallback	오류를 실제로 넘기는 상황의 효용


관측에 근거한 적용 해석. 제품 전체 성능·일반 신뢰성의 보증은 아님.

설명은 GEODE에서, 근거는 고정된 기록에서

고정 공개 근거 · artifact 3bcf4044

원결과·교정 분석·사후 진단 분리

파일럿·원결과·사후 분석을 구분한 공개 근거



이전 파일럿

구현·판정 지연 진단 · 본 실험 분모와 별도

본 실험 v3

27단위 인덱스 · 고정 spec·결과·분모·analysis

추가 근거: parser 교정 · Noul 사후 11쌍 진단

현재 파일럿 · 연구/공개 계약

github.com/mangowhoisccloud/geode

게시 commit 3bcf4044 · 원결과와 교정 분석은 별도 경로 · 미공개 입력의 범위도 명시

본 실험 · 고정 공개 README

github.com/mangowhoisccloud/geode-eval-artifacts

기존 결과 확인과 새 실험의 분리

고정 공개 근거 · artifact 3bcf4044

기존 기록의 재계산인가, 새 모델 호출인가?

공통 입구: README · commit · manifest · SHA 읽기와 무결성 확인


독자의 경로	입력과 해석 범위	실험 호출
고정 결과 재계산	Prediction / gold / clusters / 고정 분석기 Recompute: 같은 고정 입력으로 분석 재계산, 모델 재호출 없음	없음
자기 계정의 새 시행	자기 계정 · budget · 새 freeze / run ID 조건을 기록한 별도 시행 · 같은 숫자를 보장하지 않음	발생
Trajectory / Replay	공개 trajectory · 선정 Replay · source 시계와 배율 Replay: 기록된 실행을 다시 보기. 생략 확인 필요, 점수·지연의 권위는 native 결과.	없음
X2 · Mind2Web	공식 원천 → 고정 변환기 → hash 대조 · Test 본문/풀 재게시 제외 재계산 입력 누락 시 해당 범위를 검증 불가로 표시	
공개 재계산 경로: U2 · U4 · 교정 U4/X2 · Noul 사후 진단. 비공개 실행 환경 검증과는 별개.		

에이전트의 읽기 전용 근거 검토

고정 공개 근거 · artifact 3bcf4044

원결과·교정 분석·사후 진단 분리

결과 하나에서 원본 근거까지, 읽기 전용 추적



읽기 검토: 실험 API·인증 변경·새 유료 시행·T/τ 재적합 없음

검토 결과에 기록할 것: commit·입력 해시 · 수치·분모 일치 · 검증하지 못한 입력과 실행 범위

해석을 되짚는 원문과 실행 기록

확인할 질문

근거의 소유자

자료 열기

Jev의 공개 범위는 어디까지인가?

API 명세 · 공급사 설명

Primitives · System One · RLCD

[API](#) · [SDK](#)
[Launch](#) · [Interview](#)

시간과 오류가 어디서 달라졌나?

분리된 자체 측정 기록

자연 실행 6쌍 · 고정 입력 3상태 · 오류 주입 2조건

[실행 / 지표](#)

라벨이 실제 수정으로 이어졌나?

고정한 코드와 실행 기록

판정 → 피드백 → Astra → oracle

[비교 Replay](#)
[코드 / 원본](#)

배경 개념: RSI 분류 · Qwen/CLM · 이중 과정 이론 · [Reflexion \(Shinn 외, NeurIPS 2023\)](#) → [공개 연구 근거](#)

제작 레퍼런스

참고 자료 → 이 영상에 적용한 지점

[Beyond Pass Rates · GEODE ↗](#)

절제된 타이포그래피 · 주장 뒤에 실행 증거를 배치하는 전개

[Stanford CS231n · Lecture 2, pp. 7–8 ↗](#)

하나의 예시를 입력·표현·선택지로 확대하는 설명

[Anthropic · Tracing the thoughts... ↗](#)

중간 상태와 결과의 관계를 한 도식에서 따라가는 구성


[What's next after RLHF? · AI Engineer ↗](#)

Diogo Almeida · 질문과 반례로 학습 목표를 구분하는 전개

[Anthropic · LangGraph · OpenAI ↗](#)

워크플로우의 통과 조건·수정 경로·코드로 강제하는 계약

화면에 사용한 자산



TypeSafe symbol · GEODE Geodi

가 Aa

[IBM Plex Sans / KR ↗](#)

제목·본문·도식 · 코드: Plex Mono

[디자인 레퍼런스·폰트 출처 ↗](#)

빠른 verifier 호출, 판단 종류에 따라 갈린 대체 가능성

최종 native 근거 · 편집 해석

실행 원본 보존 · 교정 분석은 별도 표기

관측된 이득·손실과 그에 맞는 위임 범위

더 짧은 verifier 대기시간	-10.20 s 전체 과제 시간 단축과는 별개 120쌍 · paired median · CI [-11.34, -8.81] s
정형 의도·대상의 제한적 가능성	216/220 최종 inbox E2E는 A/B 각 3/3 Jev · Astra 220/220 · 이 패널의 -5 pp NI 충족
통제 Score 선택의 정확도 차이	-25.00 pp 이 조건의 단독 대체 근거는 부족 Noul joint -41.67 pp · 외부 선택 -12.50 pp
Noul · 정답 후보의 최종 반환	0/11 오거부와 반환 차단까지 검사 필요 후보 정답11/11 · 전달 보류11/11 · 사후4원천11쌍

도입 조건: intent·target helper의 새 입력 검증 + 최종 verifier의 오류 승인·오거부 분리 측정